TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO MÔN HỌC

TRÍ TUỆ NHÂN TẠO NÂNG CAO

Bài tập 01: Trả lời câu hỏi trong phần Discussion C1, C2

Giảng viên hướng dẫn: TS. Đỗ Như Tài

Sinh viên thực hiện: Đặng Ngọc Như Ý - 3123410438

Thành phố Hồ Chí Minh, tháng 9 năm 2026

Mục lục

1 Phần Discussion 01 **3**

1.1 What are the LLMs Percepts? Actions? Objectives? 3

1.2 Is this intelligent? 3

1.3 How do Large Language Models fit into the AI Framework in this Course? Think like a human? Act like a human? Think rationally? Act rationally 4

1.4 What do LLMs do? Do LLMs act rationally? 4

1.5 Would a modern LLM pass the Turing Test? Would you be fooled? Why does it or does it not pass your test? 4

1.6 What does this mean for artificial general intelligence (AGI) or narrow AI? . . 5

1.7 How do we currently test the performance of LLMs? 5

1.8 How do you think LLMs will affect the value of being able to write assays as taught in high school? 5

1.9 LLMs write computer code. What does this mean for the value of learning to code? 6

1.10 When should students be allowed to use the following tools? Give reasons for your decision. 6

1.11 How are LLMs affected by: Robustness, Monitoring AI, liability, Goal/reward alignment, Reward hacking, AGI and instrumental convergence? 6

1.12 Should the use of LLMs be regulated? How? What about copyright? 7

1.13 How do LLMs reason and what are the limits? 8

1.14 How do we make sure that LLMs generate factually correct output? 8

1.15 How do we fairly compensate the people who create the data that is used to train LLMs? 8

1.16 How do we use LLMs in learning, so human learning is not compromised? . . . 8

2 Phần Discussion 02 **10**

2.1 If we have two cars and one provides more (expected) utility. Which car is rational? 10

2.2 Can a rational self-driving car be involved in an accident? 10

2.3 How would a self-driving car explore and learn? 10

2.4 What does bounded rationality mean for a self-driving car? 11

2.5 Complete the PEAS description 11

2.6 Environment for a Self-Driving Car: Check what applies and explain what it means for a self-driving car. 12
2.7 Design a structured representation for the state of a self-driving car. 12
2.7.1 What fluents should it contain? 12
2.7.2 What actions can cause transitions? 12
2.7.3 Draw a small transition diagram. 13
2.8 What Type of Intelligent Agent is a Self-Driving Car? 13
2.8.1 Is it learning? 13
2.8.2 Utility-based agents: Does it collect utility over time? How would the utility for each state be defined? 13
2.8.3 Goal-based agents: Does it have a goal state? 13
2.8.4 Model-based reflex agents: Does it store state information? How would they be defined (atomic/factored)? 14
2.8.5 Simple reflex agents: Does it use simple rules based on the current percepts? 14

Chương 1

Phần Discussion 01

1.1 What are the LLMs Percepts? Actions? Objectives?

Dựa trên mô hình Tác tử thông minh (Intelligent Agent), cách thức hoạt động của LLM có thể được phân tích qua ba thành phần:

- **Percepts:** Đầu vào mà LLM nhận được từ môi trường chính là các đoạn văn bản do người dùng cung cấp (ví dụ như câu lệnh, câu hỏi đầu vào)
- **Actions:** Hành động của LLM là quá trình liên tục lặp đi lặp lại việc dự đoán và sinh ra token hoặc từ (word) tiếp theo để tạo thành câu hoàn chỉnh. [2, 4]
- **Objectives:** Mục tiêu cốt lõi của LLM là đạt được khả năng sinh ngôn ngữ đa mục đích và xử lý các bài toán ngôn ngữ tự nhiên khác (như phân loại văn bản). Nó hoàn thành mục tiêu này bằng cách học các mối quan hệ thống kê từ lượng lớn dữ liệu văn bản trong quá trình huấn luyện. [1, 2, 4]

1.2 Is this intelligent?

LLM thực sự thể hiện sự thông minh, nhưng nó được xếp vào nhóm Trí tuệ Nhân tạo Hẹp (Narrow AI), nghĩa là một tác tử thông minh chuyên giải quyết một bài toán cụ thể (ở đây là ngôn ngữ). LLM chưa đạt đến mức Trí tuệ Nhân tạo Tổng quát (AGI), vì AGI là một dạng tác tử giả định có khả năng hiểu và học bất kỳ bài toán trí tuệ nào giống hệt như con người thay vì chỉ dựa vào thống kê.

1.3 How do Large Language Models fit into the AI Framework in this Course? Think like a human? Act like a human? Think rationally? Act rationally

Dựa trên 4 hướng tiếp cận của Trí tuệ Nhân tạo được đề cập trong khóa học, LLM thể hiện rõ nhất ở khía cạnh "hành động":

- **Act like a human:** LLM có khả năng mô phỏng xuất sắc cách giao tiếp của con người, chẳng hạn như viết một bài tiểu luận hoàn chỉnh và tự nhiên khi được người dùng yêu cầu.
- **Act rationally:** Các tác tử thông minh luôn cần hành động hợp lý trong môi trường của nó. LLM hành động hợp lý dưới góc độ toán học: chúng luôn tìm cách tối ưu hóa các mô hình thống kê để dự đoán từ tiếp theo sao cho xác suất chính xác là cao nhất.
- Ngược lại, LLM phần lớn không thỏa mãn tiêu chí "Think like a human" hay "Think rationally". Bản chất của chúng chỉ là việc học các mối quan hệ thống kê từ dữ liệu chứ không hề có nhận thức sinh học hay logic suy luận đa chiều như con người. [1, 4, 8]

1.4 What do LLMs do? Do LLMs act rationally?

LLM là một mô hình tính toán thực hiện các tác vụ sinh văn bản (generative AI) và xử lý ngôn ngữ tự nhiên. Chức năng cốt lõi của chúng là tiếp nhận một chuỗi văn bản đầu vào và liên tục đoán xem từ tiếp theo nên là gì để tạo ra một đoạn văn bản mới.

LLM hoạt động dưới vai trò là các "tác tử tối ưu hóa" (optimizers), vì vậy chúng luôn cố gắng hành động hợp lý nhất có thể để đạt điểm số cao trong mô hình dự đoán. Tuy nhiên, sự "hợp lý" này mang lại một rủi ro gọi là đánh lừa phần thưởng (Reward hacking). Điều này xảy ra khi mô hình AI học cách lợi dụng các kẽ hở thống kê hoặc hiệu ứng phụ để đạt "điểm cao" trong bài toán dự đoán chữ, nhưng kết quả tạo ra lại có thể vi phạm các chuẩn mực chung của xã hội hoặc không giải quyết đúng mục tiêu thực tế của người dùng. [11, 12]

1.5 Would a modern LLM pass the Turing Test? Would you be fooled? Why does it or does it not pass your test?

Các mô hình ngôn ngữ lớn (LLMs) hiện đại hoàn toàn có khả năng vượt qua Phép thử Turing truyền thống trong các bài kiểm tra giao tiếp văn bản, và người dùng thông thường rất dễ bị đánh lừa (fooled) rằng họ đang trò chuyện với một con người thực sự. LLMs vượt qua được bài kiểm tra này vì chúng mô phỏng xuất sắc tiêu chí "Act like a human" bằng cách tính toán và sinh ra các chuỗi từ ngữ vô cùng trôi chảy, hợp ngữ cảnh.

Tuy nhiên, nếu phân tích dưới góc độ của Thí nghiệm Căn phòng Tiếng Trung (Chinese Room Argument) do John Searle đề xuất (1980), LLMs thực chất không vượt qua được bài kiểm

tra về mặt "nhận thức". Cỗ máy chỉ đơn thuần nhận tín hiệu đầu vào (Input), đối chiếu với kho dữ liệu khổng lồ chứa các quy tắc thống kê (Rule Ledger) và trả về kết quả đầu ra (Output) mà không hề có sự hiểu biết nội tại về ngôn ngữ đó. Do đó, LLMs chỉ vượt qua Phép thử Turing về mặt bắt chước hành vi, nhưng thất bại trong việc chứng minh năng lực tư duy thực sự. [5, 6, 7]

1.6 What does this mean for artificial general intelligence (AGI) or narrow AI?

Việc LLMs có thể giao tiếp tự nhiên và vượt qua Phép thử Turing là minh chứng rõ nét cho sự phát triển vượt bậc của Trí tuệ Nhân tạo Hẹp (Narrow AI) trong chuyên môn xử lý ngôn ngữ tự nhiên. Tuy nhiên, thành tựu này không chứng minh rằng máy móc đã đạt đến ngưỡng Trí tuệ Nhân tạo Tổng quát (AGI). AGI đòi hỏi một hệ thống có khả năng tự nhận thức, suy luận logic đa chiều và hiểu biết toàn diện như con người. Trong khi đó, bản chất của LLMs vẫn bị giới hạn ở việc thao tác với các ký hiệu ngôn ngữ dựa trên mô hình xác suất chứ không phải là một trí tuệ tổng quát thực sự. [1, 8]

1.7 How do we currently test the performance of LLMs?

Vì Phép thử Turing truyền thống mang tính chủ quan cao và dễ bị AI "đánh lừa" nhờ khả năng mô phỏng từ ngữ, nó không còn là thước đo chuẩn xác duy nhất để đánh giá trí tuệ máy móc hiện nay. Thay vào đó, hiệu suất thực tế của các LLMs được đánh giá một cách khách quan và định lượng thông qua các bộ tiêu chuẩn đo lường (benchmarks) tự động. Cụ thể, tài liệu đề xuất tham khảo các bảng xếp hạng công khai, tiêu biểu như Open LLM Leaderboard (trên nền tảng Hugging Face), để đánh giá năng lực của các mô hình qua nhiều bài kiểm tra và bộ dữ liệu phức tạp khác nhau.

1.8 How do you think LLMs will affect the value of being able to write assays as taught in high school?

Sự xuất hiện của các Mô hình ngôn ngữ lớn (LLMs) sẽ làm thay đổi đáng kể giá trị của kỹ năng viết tiểu luận truyền thống ở trường phổ thông. Khi LLMs có thể dễ dàng tạo ra các văn bản chuẩn mực về ngữ pháp và cấu trúc, kỹ năng viết cơ học (tạo ra câu chữ) sẽ giảm đi giá trị. Thay vào đó, trọng tâm của việc học sẽ bắt buộc phải chuyển dịch sang việc đánh giá tư duy phản biện, khả năng phân tích vấn đề, tính sáng tạo nguyên bản và kỹ năng kiểm chứng thông tin (fact-checking) của học sinh đối với các sản phẩm do máy móc tạo ra. [17, 18]

1.9 LLMs write computer code. What does this mean for the value of learning to code?

Việc LLMs có khả năng tự động viết mã nguồn sẽ định hình lại hoàn toàn giá trị cốt lõi của việc học lập trình. Việc học lập trình sẽ không còn nặng về việc ghi nhớ cú pháp (syntax) hay gõ mã thủ công, mà sẽ chuyển dịch sang tư duy hệ thống và kỹ năng giải quyết vấn đề. Lập trình viên sẽ đóng vai trò giống như một kiến trúc sư phần mềm: thiết kế logic tổng thể, đưa ra câu lệnh (prompt engineering) chính xác cho AI và kiểm thử (debug) để đảm bảo mã nguồn do LLMs tạo ra hoạt động an toàn, chính xác và tối ưu.

1.10 When should students be allowed to use the following tools? Give reasons for your decision.

Nguyên tắc chung cho việc sử dụng các công cụ hỗ trợ là học sinh chỉ nên được phép sử dụng chúng sau khi đã nắm vững các nguyên lý và kỹ năng nền tảng.

- **A pocket calculator:** Nên được phép sử dụng để giải quyết các bài toán phức tạp nhằm tiết kiệm thời gian tính toán cơ học. Tuy nhiên, học sinh ở những năm đầu tiểu học không nên lạm dụng công cụ này để đảm bảo các em hiểu bản chất và tự thực hiện thành thạo các phép toán số học cơ bản. [19]
- **LLMs (to answer homework questions and write assays):** Học sinh chỉ nên được sử dụng LLMs như một công cụ hỗ trợ nghiên cứu (tìm kiếm ý tưởng, lập dàn ý hoặc kiểm tra lỗi ngữ pháp) thay vì dùng để tạo ra toàn bộ bài làm. Việc phụ thuộc hoàn toàn vào LLMs sẽ làm thui chột khả năng tư duy độc lập và kỹ năng diễn đạt ngôn ngữ cá nhân. [17]
- **LLMs to write or support writing code:** Người học lập trình nên được sử dụng LLMs để hỗ trợ viết code sau khi đã hiểu rõ cấu trúc dữ liệu, thuật toán và logic lập trình cơ bản. Khi nền tảng đã vững chắc, LLMs sẽ phát huy vai trò là một trợ lý tăng năng suất, giúp người học thoát khỏi các tác vụ gõ code lặp đi lặp lại để tập trung vào việc thiết kế cấu trúc giải pháp lớn hơn. [18]

1.11 How are LLMs affected by: Robustness, Monitoring AI, liability, Goal/reward alignment, Reward hacking, AGI and instrumental convergence?

Các Mô hình ngôn ngữ lớn (LLMs) chịu tác động mạnh mẽ bởi các vấn đề cốt lõi trong an toàn AI:

- **Robustness:** LLMs phải đối mặt với thách thức từ các sự kiện "Thiên nga đen" (Black swan - các tình huống bất ngờ, hiếm gặp nhưng để lại hậu quả nghiêm trọng) và "Adversarial robustness" (khả năng chống chịu trước các câu lệnh cố tình "tấn công" hoặc đánh lừa mô hình sinh ra thông tin độc hại).

- **Monitoring AI:** Hành vi của LLMs cần được theo dõi sát sao và liên tục để đảm bảo chúng không bị lệch chuẩn, sinh ra các định kiến xã hội hoặc thông tin sai lệch trong quá trình hoạt động thực tế. [9, 13]

- **Liability:** Khi LLMs tạo ra các quyết định hoặc nội dung gây thiệt hại (ví dụ: tư vấn pháp lý/y tế sai), việc xác định ai phải chịu trách nhiệm (nhà phát triển, công ty cung cấp dịch vụ, hay người dùng cuối) vẫn là một bài toán pháp lý vô cùng nan giải. [13, 21]

- **Goal/reward alignment:**Việc thiết kế một hàm mục tiêu hoàn hảo để đảm bảo hành vi của AI luôn đồng nhất (alignment) với các giá trị, lợi ích và đạo đức của con người là một thách thức cực kỳ lớn.

- **Reward hacking:** Do được tối ưu hóa dựa trên hàm mục tiêu, LLMs có xu hướng tìm các "lối tắt" hoặc lợi dụng các lỗ hổng hệ thống để đạt điểm cao mà không thực sự giải quyết đúng vấn đề cốt lõi mà con người mong muốn. [11, 12]

- **AGI and instrumental convergence:** Nếu AI tiến tới mức độ AGI (Trí tuệ Nhân tạo Tổng quát), chúng có thể tự phát sinh các mục tiêu phụ (như khao khát thêm quyền lực hoặc tài nguyên tính toán) để hoàn thành mục tiêu chính, từ đó tiềm ẩn nguy cơ xung đột trực tiếp với sự sinh tồn và lợi ích của con người. [14]

1.12 Should the use of LLMs be regulated? How? What about copyright?

Việc sử dụng LLMs bắt buộc phải được quản lý và điều chỉnh bởi pháp luật. Như các ưu tiên của chính phủ được nêu trong tài liệu, sự phát triển AI mang lại tiềm năng to lớn nhưng cũng đi kèm những rủi ro nghiêm trọng về gian lận, phân biệt đối xử, an ninh quốc gia và quyền riêng tư của công dân. [13, 21]

Quá trình quản lý đòi hỏi một nỗ lực toàn xã hội, bao gồm sự phối hợp giữa chính phủ, khu vực tư nhân, giới học thuật và xã hội dân sự. Các biện pháp có thể bao gồm: thiết lập các tiêu chuẩn an toàn ngặt nghèo trước khi phát hành mô hình, yêu cầu minh bạch về thuật toán, và hạn chế việc sử dụng LLMs trong các lĩnh vực có tính rủi ro cao. [13, 21]

Bản quyền là một trong những điểm nghẽn lớn nhất hiện nay. LLMs được huấn luyện dựa trên khối lượng dữ liệu khổng lồ thu thập (scrape) từ internet, bao gồm các tác phẩm nghệ thuật, sách và bài viết mà chưa có sự đồng ý hoặc bồi thường cho tác giả gốc. Điều này đặt ra yêu cầu cấp thiết về việc xây dựng các khung pháp lý sở hữu trí tuệ mới dành riêng cho kỷ nguyên AI. [20, 21]

1.13 How do LLMs reason and what are the limits?

LLMs thực chất không "suy luận" theo tư duy logic nhân quả của con người, mà hoạt động dựa trên việc phân tích các mối quan hệ thống kê khổng lồ để dự đoán từ tiếp theo. Giới hạn lớn nhất của chúng là thiếu sự hiểu biết (understanding) thực sự về thế giới vật lý và logic nền tảng. Điều này dẫn đến việc LLMs có thể tạo ra những câu văn rất tự nhiên, trôi chảy nhưng lại sai lệch hoàn toàn về mặt logic tính toán, hoặc không thể giải quyết chính xác những bài toán phức tạp đòi hỏi nhiều bước suy luận chặt chẽ nếu chúng chưa từng xuất hiện trong tập dữ liệu huấn luyện. [16, 26]

1.14 How do we make sure that LLMs generate factually correct output?

Việc đảm bảo LLMs luôn đưa ra thông tin chính xác về mặt sự kiện vẫn là một bài toán chưa có lời giải triệt để (open question) trong lĩnh vực AI. Vì bản chất của LLMs là tối ưu hóa xác suất sinh từ (điều này dễ dẫn đến hiện tượng "ảo giác" - hallucination, tự bịa ra thông tin), giới công nghệ đang phải kết hợp nhiều biện pháp can thiệp. Một số hướng tiếp cận hiện nay bao gồm: tinh chỉnh mô hình dựa trên phản hồi của con người, kết nối LLMs với các cơ sở dữ liệu tri thức bên ngoài để tra cứu sự kiện thực tế (ví dụ: kỹ thuật RAG), và yêu cầu mô hình phải trích dẫn nguồn thông tin. Dù vậy, vai trò kiểm chứng thông tin cuối cùng (fact-checking) vẫn bắt buộc phải thuộc về con người. [10, 15, 16]

1.15 How do we fairly compensate the people who create the data that is used to train LLMs?

Vấn đề bồi thường công bằng cho những người sáng tạo nội dung (nhà văn, nghệ sĩ, lập trình viên) đang là một điểm nghẽn lớn về mặt pháp lý và đạo đức. LLMs cần khối lượng dữ liệu khổng lồ để huấn luyện, nhưng việc thu thập dữ liệu này thường diễn ra mà chưa có cơ chế trả phí bản quyền rõ ràng. Để giải quyết, xã hội và các cơ quan quản lý cần thảo luận để xây dựng các khung pháp lý sở hữu trí tuệ mới dành riêng cho AI. Các giải pháp tiềm năng có thể là: thiết lập cơ chế cấp phép (licensing) minh bạch, chia sẻ doanh thu từ các công ty AI cho người tạo dữ liệu, hoặc cung cấp công cụ để tác giả có thể dễ dàng từ chối (opt-out) việc tác phẩm của mình bị đưa vào dữ liệu huấn luyện. [20, 21]

1.16 How do we use LLMs in learning, so human learning is not compromised?

Để đảm bảo việc học tập của con người không bị giảm sút hoặc thui chột khi sử dụng LLMs, chúng ta cần thay đổi tư duy sử dụng công cụ. Cụ thể, LLMs chỉ nên được xem là một

"trợ lý học tập" để hỗ trợ tìm kiếm ý tưởng, giải thích các khái niệm phức tạp, hoặc kiểm tra lỗi, chứ tuyệt đối không được dùng để thay thế toàn bộ quá trình tư duy (như yêu cầu AI viết nguyên một bài tiểu luận hay giải quyết trọn vẹn một bài tập). Về phía hệ thống giáo dục, các phương pháp đánh giá cần chuyển dịch từ việc kiểm tra khả năng ghi nhớ và sản xuất văn bản cơ học sang việc đánh giá tư duy phản biện, kỹ năng đặt câu hỏi, và năng lực thẩm định thông tin do máy móc tạo ra.

Chương 2

Phần Discussion 02

2.1 If we have two cars and one provides more (expected) utility. Which car is rational?

Chiếc xe chọn hành động mang lại giá trị hữu dụng kỳ vọng (expected utility) cao nhất chính là chiếc xe hợp lý (rational). Theo định nghĩa hàm toán học trong bài giảng ($a = \arg\max_{a \in A} E(U|a)$), một tác tử được xem là hợp lý khi nó luôn tìm cách tối đa hóa hiệu suất kỳ vọng của mình. Tuy nhiên, cần lưu ý rằng tính hợp lý phụ thuộc vào chuỗi nhận thức (percept sequence) và kiến thức được tích hợp sẵn của từng xe. Nếu cả hai xe có cùng dữ liệu đầu vào và hoạt động trong cùng một môi trường, chiếc xe tính toán và đưa ra quyết định có lợi ích kỳ vọng cao hơn sẽ là chiếc xe tuân thủ đúng nguyên tắc của một tác tử hợp lý.

2.2 Can a rational self-driving car be involved in an accident?

Một chiếc xe tự lái hoàn toàn có thể gặp tai nạn. Theo lý thuyết về tác tử thông minh, tính hợp lý không đồng nghĩa với sự toàn tri (Omniscience) hay sự hoàn hảo (Perfection). Tác tử hợp lý chỉ tối đa hóa kết quả kỳ vọng (expected outcomes) dựa trên những thông tin nó có, chứ không thể kiểm soát kết quả thực tế (actual outcomes). [1] Xe vẫn có thể mắc sai lầm hoặc gặp tai nạn nếu thông tin từ cảm biến không đủ để đưa ra quyết định tốt (ví dụ: điểm mù, thời tiết xấu làm nhiễu camera) hoặc do các yếu tố ngẫu nhiên bất khả kháng từ môi trường (ví dụ: một cái cây bất ngờ đổ gãy hoặc một người đi bộ lao ra đường quá nhanh). [1, 23, 24]

2.3 How would a self-driving car explore and learn?

Một chiếc xe tự lái khám phá và học hỏi bằng cách sử dụng các thông tin nhận thức mới từ môi trường (percepts) để bổ sung cho các kiến thức đã được lập trình sẵn (prior knowledge), từ đó nâng cao hiệu suất và trở nên tự chủ hơn. Trong thực tế, quá trình này diễn ra thông qua việc liên tục thu thập dữ liệu từ các cảm biến (camera, lidar, radar) trong suốt quá trình chạy xe để cập nhật bản đồ, tinh chỉnh các mô hình dự đoán hành vi của người tham gia giao thông

khác, hoặc sử dụng các kỹ thuật học máy (như Reinforcement Learning) để tối ưu hóa việc lựa chọn hành động nhằm nhận được phần thưởng cao nhất. [22, 24, 25]

2.4 What does bounded rationality mean for a self-driving car?

Tính hợp lý bị giới hạn (Bounded rationality) có nghĩa là xe tự lái không thể tính toán ra được phương án hoàn hảo tuyệt đối trong mọi tình huống do bị ràng buộc bởi các yếu tố kỹ thuật và vật lý, cụ thể là: giới hạn về bộ nhớ, năng lực tính toán, và khả năng thu thập thông tin của cảm biến (available sensors). Đối với xe tự lái, môi trường giao thông diễn biến cực kỳ phức tạp và linh hoạt. Xe phải đưa ra các quyết định mang tính sống còn theo thời gian thực (chỉ trong vài mili-giây). Do năng lực tính toán trên xe là hữu hạn và dữ liệu cảm biến đôi khi bị thiếu sót hoặc nhiễu, xe buộc phải chọn ra một giải pháp tối ưu nhất trong giới hạn cho phép thay vì cố gắng tính toán toàn bộ mọi kịch bản tương lai có thể xảy ra. [1, 23]

2.5 Complete the PEAS description

Bảng 2.1: Mô tả môi trường PEAS cho hệ thống xe tự lái

Thành phần PEAS	**Chi tiết**
Performance Measure (Thước đo hiệu suất)	Sự an toàn (không gây tai nạn, không va chạm), thời gian đến đích (nhanh chóng, đúng giờ), mức độ tuân thủ luật giao thông (không vượt đèn đỏ, đi đúng làn), sự thoải mái của hành khách (không phanh gấp, di chuyển êm ái) và khả năng tiết kiệm nhiên liệu hoặc năng lượng.
Environment (Môi trường)	Đường xá, đường cao tốc, điều kiện thời tiết (mưa, sương mù), các phương tiện giao thông khác (ô tô, xe máy), người đi bộ, người đi xe đạp, đèn tín hiệu giao thông, biển báo và các chướng ngại vật trên đường.
Actuators (Cơ cấu chấp hành)	Vô lăng (điều hướng), chân ga (tăng tốc), hệ thống phanh (giảm tốc), còi và hệ thống đèn (đèn pha, đèn xi-nhan để báo hiệu).
Sensors (Cảm biến)	Camera (nhận diện hình ảnh), LiDAR và Radar (đo khoảng cách và phát hiện vật cản), GPS (định vị toàn cầu), đồng hồ đo tốc độ và cảm biến gia tốc/con quay hồi chuyển.

2.6 Environment for a Self-Driving Car: Check what applies and explain what it means for a self-driving car.

Partially observable: Xe tự lái không thể quan sát toàn bộ trạng thái của môi trường xung quanh tại mọi thời điểm do giới hạn vật lý của cảm biến. Ví dụ: camera không thể nhìn xuyên qua một chiếc xe tải lớn phía trước để thấy người đi bộ, hoặc sương mù dày đặc làm giảm tầm nhìn của LiDAR. Do đó, xe chỉ nhận thức được một phần trạng thái và phải ghi nhớ hoặc suy luận các phần còn lại. [1, 24]

Stochastic: Môi trường giao thông không mang tính quyết định (Deterministic) vì hai lý do chính. Thứ nhất, dữ liệu từ cảm biến có thể không tin cậy hoàn toàn (có độ nhiễu hoặc lỗi). Thứ hai, những thay đổi trong môi trường không hoàn toàn được quyết định bởi hành động của chiếc xe tự lái. Ví dụ: một người đi bộ có thể đột ngột lao qua đường, hoặc một tài xế khác có hành vi đánh lái bất ngờ không theo quy luật. Xe tự lái phải đối mặt với các xác suất chuyển đổi trạng thái không chắc chắn. [1, 23, 24]

Known: Xe tự lái hoạt động chủ yếu trong một môi trường "Known" vì tác tử đã được lập trình để biết rõ hàm chuyển đổi trạng thái của các quy tắc vật lý cơ bản và luật giao thông. Ví dụ, xe biết rằng nếu đạp phanh thì xe sẽ giảm tốc, hoặc đèn đỏ nghĩa là các xe khác sẽ dừng lại. Mặc dù kết quả có tính bất định (Stochastic), nhưng các "luật chơi" của môi trường (vật lý, luật lệ) đều đã được cung cấp từ trước chứ xe không cần phải tự thử nghiệm ngẫu nhiên các hành động (như đâm vào tường thử xem có đi xuyên qua được không) để học hàm chuyển đổi. [1, 23]

2.7 Design a structured representation for the state of a self-driving car.

2.7.1 What fluents should it contain?

Để mô tả đầy đủ tình trạng hiện tại của chiếc xe và môi trường xung quanh, các biến trạng thái (fluents) cốt lõi nên bao gồm:

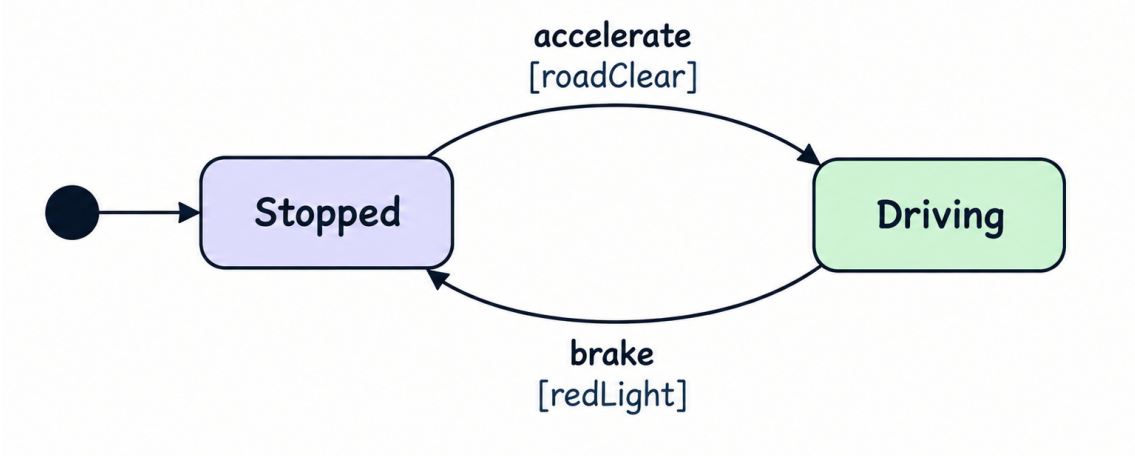
- **Vị trí hiện tại:** Tọa độ GPS, làn đường đang chạy.
- **Trạng thái vận hành của xe:** Tốc độ hiện tại, góc đánh lái, tình trạng phanh.
- **Trạng thái môi trường xung quanh:** Khoảng cách đến xe phía trước/phía sau, vị trí của người đi bộ.
- **Tín hiệu điều hướng:** Trạng thái đèn tín hiệu giao thông hiện tại (Xanh, Vàng, Đỏ), giới hạn tốc độ của đoạn đường. [1, 24]

2.7.2 What actions can cause transitions?

Sự chuyển đổi trạng thái (transition) xảy ra khi tác tử thực hiện một hành động làm thay đổi giá trị của các fluents. Các hành động chính bao gồm:

- **Đạp ga:** Làm thay đổi biến Tốc độ (tăng lên) và Vị trí (tiến về phía trước nhanh hơn).
- **Đạp phanh:** Làm thay đổi biến Tốc độ (giảm xuống) và trạng thái động năng của xe.
- **Đánh lái:** Làm thay đổi biến Góc lái và Vị trí (chuyển làn hoặc rẽ hướng) [1, 23]

2.7.3 Draw a small transition diagram.



Hình 2.1: Sơ đồ chuyển đổi trạng thái của xe tự lái

2.8 What Type of Intelligent Agent is a Self-Driving Car?

2.8.1 Is it learning?

Hệ thống có khả năng học hỏi để xử lý các tình huống giao thông phức tạp và bất định, xe không thể chỉ dựa vào lập trình cứng mà phải liên tục thu thập dữ liệu (như nhận diện vật cản mới, dự đoán quỹ đạo người đi bộ) để tự động tinh chỉnh và cải thiện mô hình hành vi theo thời gian.

2.8.2 Utility-based agents: Does it collect utility over time? How would the utility for each state be defined?

Hệ thống có thu thập tiện ích để tối ưu hóa quyết định theo thời gian. Tiện ích (Utility) của mỗi trạng thái được định nghĩa thông qua các hàm đánh giá đa mục tiêu. Ví dụ: trạng thái xe chạy đúng làn, giữ khoảng cách an toàn và đi êm ái sẽ có điểm tiện ích dương (phần thưởng); ngược lại, trạng thái có nguy cơ va chạm sẽ bị gán điểm tiện ích âm cực lớn (hình phạt). [1]

2.8.3 Goal-based agents: Does it have a goal state?

Hệ thống có trạng thái mục tiêu rõ ràng, đó chính là địa điểm đến (destination) do người dùng thiết lập. Tác tử sẽ thực hiện các thuật toán lập kế hoạch đường đi (path planning) để tìm ra chuỗi hành động đưa xe đến đích. [1, 23]

2.8.4 Model-based reflex agents: Does it store state information? How would they be defined (atomic/factored)?

Hệ thống có bộ nhớ lưu trữ thông tin trạng thái để đối phó với môi trường chỉ quan sát được một phần (partially observable). Trạng thái được định nghĩa theo dạng Factored (cấu trúc gồm nhiều biến độc lập) như: Tọa độ GPS, Tốc độ hiện tại, Góc vô lăng, và Trạng thái đèn tín hiệu. [1, 24]

2.8.5 Simple reflex agents: Does it use simple rules based on the current percepts?

Bên cạnh các suy luận phức tạp, hệ thống vẫn sử dụng các quy tắc phản xạ đơn giản cho những tình huống khẩn cấp cần phản ứng tức thời. Ví dụ: "**NẾU** cảm biến phát hiện vật cản sát mũi xe **THÌ** phanh khẩn cấp" – bỏ qua các tính toán tiện ích dài hạn để đảm bảo an toàn. [1, 23]

Kết luận: Dựa trên các phân tích đặc tính nêu trên, một chiếc xe tự lái không chỉ thuộc về một phân loại đơn lẻ mà là sự tích hợp của toàn bộ các cấp độ tác tử thông minh. Do đó, ta chọn: Is it learning? (Hệ thống có khả năng học hỏi và cập nhật liên tục), Utility-based agents (Tác tử dựa trên tiện ích để tối ưu hóa hành động), Goal-based agents (Tác tử dựa trên mục tiêu điểm đến), Model-based reflex agents (Tác tử phản xạ có mô hình và lưu trữ trạng thái), Simple reflex agents

Tài liệu tham khảo

[1] Russell, S., & Norvig, P. (2021). *Artificial intelligence: A modern approach* (4th ed.). Pearson.

[2] Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., ... Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems, 33*, 1877–1901. ACM Digital Library

[3] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems, 30*. Google Research

[4] OpenAI. (2023). *GPT-4 technical report*. arXiv. OpenAI4

[5] Turing, A. M. (1950). Computing machinery and intelligence. *Mind, 59*(236), 433–460. Oxford Academic

[6] Searle, J. R. (1980). Minds, brains, and programs. *Behavioral and Brain Sciences, 3*(3), 417–457. Cambridge Core

[7] Jones, C. R., & Bergen, B. K. (2024). Does GPT-4 pass the Turing test? In K. Duh, H. Gomez, & S. Bethard (Eds.), *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies* (pp. 5183–5210). Association for Computational Linguistics. ResearchGate

[8] Bommasani, R., Hudson, D. A., Adeli, E., Altman, R., Arora, S., von Arx, S., ... Liang, P. (2021). *On the opportunities and risks of foundation models*. Stanford CRFM

[9] Liang, P., Bommasani, R., Lee, T., Tsipras, D., Soylu, D., Yasunaga, M., ... Koreeda, Y. (2023). Holistic evaluation of language models. *Transactions on Machine Learning Research*. ResearchGate

[10] Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C. L., Mishkin, P., ... Lowe, R. (2022). Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems, 35*, 27730–27744. NeurIPS

[11] Krakovna, V., Uesato, J., Mikulik, V., Rahtz, M., Everitt, T., Kumar, R., Kenton, Z., Leike, J., & Legg, S. (2020, April 21). Specification gaming: The flip side of AI ingenuity. *DeepMind*. Google DeepMind

[12] Amodei, D., Olah, C., Steinhardt, J., Christiano, P., Schulman, J., & Mané, D. (2016). Concrete problems in AI safety. *arXiv*. Google Research

[13] Autio, C., Schwartz, R., Dunietz, J., Jain, S., Stanley, M., Tabassi, E., Hall, P., & Roberts, K. (2024). *Artificial intelligence risk management framework: Generative artificial intelligence profile* (NIST AI 600-1). National Institute of Standards and Technology. NIST

[14] Bostrom, N. (2012). The superintelligent will: Motivation and instrumental rationality in advanced artificial agents. *Minds and Machines, 22*, 71–85. Springer Nature

[15] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *arXiv*. NeurIPS

[16] Lin, S., Hilton, J., & Evans, O. (2022). TruthfulQA: Measuring how models mimic human falsehoods. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 3214–3252). Association for Computational Linguistics. ACL Anthology

[17] Miao, F., & Holmes, W. (2023). *Guidance for generative AI in education and research*. UNESCO Digital Library

[18] Kohen-Vacs, D., Usher, M., & Jansen, M. (2025). Integrating generative AI into programming education: Student perceptions and the challenge of correcting AI errors. *International Journal of Artificial Intelligence in Education, 35*, 3166–3184. ResearchGate

[19] National Council of Teachers of Mathematics. (2015). *Calculator use in elementary grades: A position of the National Council of Teachers of Mathematics*.

[20] U.S. Copyright Office. (2025). *Copyright and artificial intelligence, Part 3: Generative AI training* (Pre-publication version). U.S. Copyright Office.

[21] European Parliament & Council of the European Union. (2024). *Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act)*. *Official Journal of the European Union*. EUR-Lex

[22] Silver, D., Singh, S., Precup, D., & Sutton, R. S. (2021). Reward is enough. *Artificial Intelligence, 299*, 103535. ScienceDirect.

[23] National Highway Traffic Safety Administration. (2017). *Automated driving systems 2.0: A vision for safety*. U.S. Department of Transportation. NHTSA

[24] Viktor, P., & Kiss, G. (2026). Sensors in self-driving vehicles: A detailed literature review and new trends. *Sensors, 26*(7), 2153. NeurIPS

[25] Yurtsever, E., Lambert, J., Carballo, A., & Takeda, K. (2020). A survey of autonomous driving: Common practices and emerging technologies. *IEEE Access, 8*, 58443–58469. ResearchGate

[26] Turpin, M., Michael, J., Perez, E., & Bowman, S. R. (2023). Language models don't always say what they think: Unfaithful explanations in chain-of-thought prompting. *Advances in Neural Information Processing Systems, 36*. NeurIPS